Predicción de decisiones de compra de billetes de avión mediante Aprendizaje Automático a Gran Escala

Jaime Morales Castro — Nicolás Pernas Gómez

Universidade da Coruña, A Coruña, España

Abstract. Este trabajo desarrolla un modelo de aprendizaje automático para recomendar cuándo comprar o esperar ante una búsqueda de vuelo. Utilizando datos de Expedia y Apache Spark, se comparan cuatro algoritmos de clasificación sobre más de tres millones de observaciones. El modelo seleccionado, Gradient-Boosted Trees, alcanza un AUC-PR de 0,6025 y un ahorro estimado de 20,04 dólares por búsqueda en el conjunto de prueba.

Keywords: Aprendizaje automático · Apache Spark · Precios de vuelos · Clasificación binaria

1 Introducción

La variabilidad de los precios de los billetes de avión hace que el momento de compra sea relevante para los consumidores. Anticipar posibles cambios en las tarifas puede ayudar a reducir el coste de los viajes.

Este trabajo aborda el problema mediante un enfoque de aprendizaje automático cuyo objetivo es determinar, para una búsqueda de vuelo concreta, si resulta más conveniente comprar el billete en ese momento o esperar. El problema se formula como una tarea de clasificación binaria: se recomienda esperar cuando el precio del mismo itinerario disminuye al menos un 5 % durante los siete días posteriores a la búsqueda; en caso contrario, se recomienda comprar.

Para desarrollar este sistema se utiliza un conjunto de datos de precios de vuelos procedente de Expedia. Debido a su volumen, el procesamiento requiere técnicas de computación distribuida, por lo que se emplea Apache Spark para abordar las distintas etapas del proyecto, desde la preparación de los datos hasta el entrenamiento y la evaluación de los modelos, comparando el rendimiento predictivo de varios algoritmos y el ahorro económico de sus decisiones.

2 Datos y preprocesamiento

El proyecto utiliza el conjunto de datos *Expedia Flight Prices*, obtenido de Kaggle, que contiene aproximadamente 82 millones de registros y ocupa alrededor de 31 GB. Cada observación recoge información sobre una búsqueda de vuelo, incluyendo fechas, itinerario, aerolíneas y precios.

En particular, se consideraron vuelos transcontinentales entre la costa oeste y la costa este de Estados Unidos, tomando como aeropuertos de origen LAX y SFO, y

como destinos JFK, EWR y BOS, en ambos sentidos. Esta selección comprende 12 rutas dirigidas y dio lugar a un conjunto inicial de 6.147.167 observaciones correspondientes a 518.540 itinerarios.

Posteriormente, se aplicaron varios filtros para garantizar que las observaciones dispusieran de información suficiente para el análisis temporal. En primer lugar, se eliminaron los registros de noviembre, ya que las búsquedas disponibles finalizaban el 5 de octubre y no permitían observar la evolución posterior de los precios durante el horizonte de análisis. También se descartaron las observaciones para las que no existían al menos cinco registros del mismo itinerario en una ventana de siete días. Sin esta condición la proporción de casos positivos oscilaba entre el 20,67 % y el 43,56 % según la densidad de observación de cada itinerario; exigiendo cinco registros, esa diferencia baja de 23 a 9 puntos. Por último, se excluyeron los vuelos cuya fecha de salida se encontraba a menos de siete días de la fecha de búsqueda.

Tras estas operaciones, se obtuvo un conjunto de datos final de 3.145.954 observaciones, correspondientes a 179.278 itinerarios y con 50 variables.

3 Etiquetado y metodología

El problema se formula como una tarea de clasificación binaria cuyo objetivo es determinar si conviene comprar un billete en el momento de la búsqueda o esperar a una posible reducción de su precio. Para construir la variable objetivo, se analiza la evolución del precio de cada itinerario durante los siete días posteriores a cada observación. Se asigna la etiqueta positiva (*ESPERAR*, $label = 1$) cuando el precio mínimo observado en dicho intervalo es, al menos, un 5 % inferior al precio actual. En caso contrario, se asigna la etiqueta negativa (*COMPRAR YA*, $label = 0$).

Formalmente, para una observación con precio actual P_t, la etiqueta se define como:

$$label_t = \begin{cases} 1, & \text{si } \min\limits_{s \in (t, t+7]} P_s \leq 0.95 P_t, \\ 0, & \text{en caso contrario.} \end{cases}$$

donde P_s representa el precio de una observación posterior del mismo itinerario dentro de los siete días siguientes a la búsqueda actual.

Ambos parámetros se fijaron con datos. Se descartó una definición alternativa basada en el precio mínimo hasta la fecha de salida porque su proporción de positivos pasaba del 25,87 % al 66,63 % según cuántas veces se hubiera observado el itinerario, dato desconocido al buscar. Y el margen del 5 % resulta robusto: la distribución de las variaciones de precio está casi vacía en ese entorno, con mediana en el 2,05 % y tercer cuartil en el 17,56 %, de modo que cualquier umbral entre el 2 % y el 7 % produce un conjunto equivalente.

La construcción de esta variable requiere disponer de observaciones posteriores de un mismo itinerario. Por ello, se mantiene el orden temporal de los registros y se descartan aquellos casos que no cuentan con información suficiente para determinar la evolución del precio. Asimismo, las características utilizadas por los modelos se construyen exclusivamente a partir de información disponible en el momento de la

búsqueda, evitando incorporar datos futuros que puedan producir fuga de información (*data leakage*).

Para evaluar los modelos en condiciones próximas a un escenario real, se realiza una partición temporal basada en la fecha de salida del vuelo (*flightDate*), asignando aproximadamente un 65 % de los datos a entrenamiento, un 15 % a validación y el 20 % restante a prueba. Esta estrategia permite entrenar con observaciones asociadas a fechas de salida anteriores y evaluar el comportamiento de los modelos sobre observaciones correspondientes a fechas de salida posteriores.

El conjunto resultante contiene 2.059.136 observaciones de entrenamiento, 462.615 de validación y 624.203 de prueba. La proporción de casos positivos (*ESPERAR*) es del 49,49 % en entrenamiento, del 43,76 % en validación y del 37,70 % en prueba. Esta variación refleja diferencias en la distribución de las etiquetas entre los conjuntos definidos por la fecha de salida, lo que refuerza la importancia de evaluar los modelos mediante una partición temporal en lugar de una división aleatoria.

4 Modelos y experimentación

A partir de los datos preprocesados se construyeron tres grupos de variables predictoras. El primero recoge características propias del vuelo: antelación respecto a la fecha de salida, duración, distancia, aerolínea, ruta y disponibilidad de asientos. El segundo describe la evolución histórica del precio del itinerario, calculada exclusivamente con observaciones anteriores, e incluye el número de búsquedas previas, el precio mínimo histórico y la desviación del precio actual respecto a dicho mínimo. El tercero caracteriza el contexto del mercado para cada ruta y día mediante el número de alternativas disponibles, el precio mínimo y su dispersión, y la posición relativa del precio actual dentro de ese conjunto. Se incorporó además la clase tarifaria, obtenida del primer carácter del código *fare basis*.

El entrenamiento se realizó mediante Apache Spark MLlib, utilizando un *pipeline* de procesamiento que integra la preparación de las variables y el aprendizaje. Los parámetros de preprocesamiento se ajustaron exclusivamente con el conjunto de entrenamiento, aplicándose posteriormente a los conjuntos de validación y prueba. Se evaluaron cuatro algoritmos de clasificación: regresión logística, árbol de decisión, bosque aleatorio (*Random Forest*) y *Gradient-Boosted Trees* (GBT).

La selección de hiperparámetros se llevó a cabo mediante una búsqueda en rejilla (*grid search*), evaluando las distintas configuraciones sobre el conjunto de validación. Como criterio principal de selección se utilizó el área bajo la curva precisión-recall (AUC-PR), que permite evaluar la capacidad de discriminación del modelo teniendo especialmente en cuenta el rendimiento sobre la clase positiva.

La rejilla comprendió 17 configuraciones, y la seleccionada para GBT fue de 100 iteraciones y profundidad máxima 6. No se empleó *CrossValidator* porque sus particiones aleatorias romperían la separación temporal, repartiendo observaciones de un mismo itinerario entre entrenamiento y validación.

Finalmente, se realizó un análisis específico del umbral de decisión. En lugar de utilizar el umbral convencional de 0,5, se estudiaron distintos valores sobre las prob-

abilidades estimadas por los modelos, seleccionando aquel que maximizaba el ahorro económico en validación.

5 Resultados y evaluación

La comparación de los modelos sobre el conjunto de validación muestra que los métodos basados en árboles ofrecen mejores resultados que la regresión logística. El mejor rendimiento corresponde a Gradient-Boosted Trees (GBT), con un AUC-PR de 0,6800, seguido de Random Forest, con 0,6752. El árbol de decisión y la regresión logística obtienen valores de 0,6119 y 0,5874, respectivamente. Por tanto, se seleccionó GBT como modelo final.

Table 1: Resultados sobre el conjunto de prueba.

Modelo	Umbral	AUC-PR	AUC-ROC	F1	Ahorro ($/búsq.)
Regresión logística	0,10	0,5471	0,6763	0,2387	19,54
Árbol de decisión	0,15	0,5410	0,6954	0,3191	19,86
Random Forest	0,25	0,6057	0,7372	0,3710	20,03
GBT	0,15	0,6025	0,7339	0,3736	20,04
Esperar siempre	–	–	–	–	19,47
Comprar siempre	–	–	–	–	0,00

Una vez seleccionado el modelo y fijado el umbral de decisión a partir del conjunto de validación, se realizó la evaluación sobre el conjunto de prueba. GBT obtuvo un AUC-PR de 0,6025 y un AUC-ROC de 0,7339. Como referencia, un clasificador aleatorio obtendría un AUC-PR igual a la proporción de positivos del conjunto, 0,3770, por lo que el resultado lo supera en un 60 %. Con un umbral de 0,15, alcanzó una precisión del 0,4107 y una exhaustividad (*recall*) del 0,9870 para la clase ESPERAR, con un F1 de 0,3736 y una exactitud del 0,4613. Estos resultados muestran que el modelo identifica la gran mayoría de las oportunidades de espera, aunque su precisión moderada indica que una parte importante de las recomendaciones de esperar no va acompañada de una reducción del precio igual o superior al 5 %.

Desde el punto de vista económico, el umbral de 0,15 maximizó el ahorro estimado en el conjunto de validación, con 25,56 dólares por búsqueda. Sobre el conjunto de prueba, GBT alcanzó 20,04 dólares por búsqueda, frente a los 19,47 de la estrategia de esperar siempre; ambas cifras no son comparables entre sí, ya que la proporción de positivos difiere entre los dos conjuntos. Con el umbral convencional de 0,5 el ahorro desciende a XX,XX dólares, una diferencia de XX,XX. Ese umbral es además el que maximiza el F1, lo que muestra que la métrica de clasificación y la utilidad económica conducen a puntos de operación distintos.

Un aspecto especialmente relevante es el comportamiento de las recomendaciones de compra inmediata. El modelo emitió 58.710 recomendaciones COMPRAR YA (9,41 % de las observaciones). Estas permitieron evitar pérdidas estimadas en 473.148,10 dólares, aunque también supusieron renunciar a 114.585,75 dólares de ahorro potencial.

El balance neto fue de 358.562,35 dólares, equivalente a 6,11 dólares por recomendación.

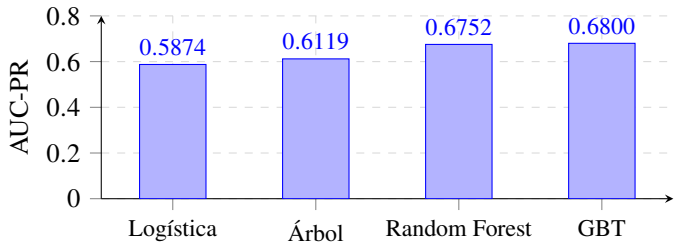


Fig. 1: Comparación del AUC-PR de los modelos en el conjunto de validación.

En el conjunto de prueba los resultados de GBT y Random Forest son muy próximos: el primero obtiene mejor F1 y ahorro, y el segundo mejor AUC-PR y AUC-ROC, con diferencias del orden de las milésimas. Ello sugiere que la ventaja de uno sobre otro no es concluyente y refuerza el uso de una métrica independiente del umbral para la selección.

6 Discusión y conclusiones

Los resultados obtenidos muestran que los modelos basados en árboles son los más adecuados para el problema planteado, destacando GBT por su rendimiento en validación. La importancia de las variables de este modelo permite identificar algunos de los factores más relevantes para la predicción. La clase tarifaria presenta la mayor importancia (0,1367), seguida de la ruta (0,0988), la aerolínea (0,0959) y la antelación respecto a la salida (0,0842). También destacan el número de observaciones históricas y las variables relacionadas con la evolución previa y el contexto de mercado. Estos resultados indican que las características del vuelo y su contexto temporal y de mercado aportan información relevante para predecir la evolución posterior de los precios.

Desde una perspectiva económica, el modelo seleccionado alcanza un ahorro estimado de 20,04 dólares por búsqueda en el conjunto de prueba, frente a los 19,47 dólares de la estrategia de esperar siempre. Aunque la mejora respecto a esta estrategia es moderada (0,57 dólares adicionales por búsqueda), el análisis de las recomendaciones de compra inmediata muestra un balance neto positivo, con un beneficio estimado de 6,11 dólares por recomendación. Por tanto, la utilidad del sistema no debe valorarse exclusivamente mediante métricas de clasificación, sino también considerando las consecuencias económicas de las decisiones que propone.

El estudio presenta algunas limitaciones. En primer lugar, los datos se restringen a un conjunto concreto de rutas transcontinentales de Estados Unidos, por lo que los resultados no pueden generalizarse directamente a otros mercados o tipos de vuelo. Además, el filtro de cinco observaciones en ventana limita la validez del modelo a itinerarios con un seguimiento casi diario, y el sesgo asociado a la densidad de observación se redujo pero no se eliminó por completo.

De mayor alcance es que los datos solo contienen itinerarios que permanecieron disponibles, por lo que no recogen el coste de que un vuelo se agote. Este sesgo se cuantificó sobre el conjunto sin filtrar: el 5,07 % de las observaciones corresponden a itinerarios que dejan de aparecer antes de la salida, y esa proporción varía monótonamente con la disponibilidad declarada, del 10,19 % con un asiento al 3,38 % con siete, lo que respalda interpretarla como agotamiento. Cuando ocurre, la mejor alternativa comparable ha empeorado el doble de veces que cuando el itinerario permanece. La penalización esperada es de 0,41 dólares por búsqueda, que reduce el ahorro de esperar siempre a 19,06 y el del modelo a 19,67, ampliando su ventaja de 0,57 a 0,61. Es una corrección agregada, ya que esas observaciones quedan fuera del conjunto de prueba por construcción.

Por último, el ahorro calculado constituye una estimación basada en el comportamiento histórico de los precios y no garantiza que las mismas oportunidades estén disponibles para cualquier usuario en condiciones reales de compra. Tampoco se ha realizado un análisis de calibración de las probabilidades estimadas, del que depende la selección del umbral.

En conclusión, se ha desarrollado un flujo de trabajo de aprendizaje automático a gran escala utilizando Apache Spark para abordar un problema de decisión sobre precios de vuelos. La combinación de variables históricas, características del vuelo e información de mercado, junto con la selección económica del umbral de decisión, permite obtener recomendaciones con un ahorro estimado ligeramente superior al de la estrategia de referencia de esperar siempre. Como trabajo futuro, sería interesante ampliar el conjunto de rutas, incorporar nuevas fuentes de información y estudiar técnicas de calibración de probabilidades para mejorar la fiabilidad de las recomendaciones.