UNIVERSIDADE DA CORUÑA

Facultade de Informática

Grao en Ciencia e Enxeñaría de Datos

Aprendizaje Automático I

Sonar - Clasificación de Minas y Rocas
(UCI Machine Learning Repository)

Jaime Morales Castro

23 de junio de 2025

Índice

1. Introducción **2**

2. Descripción del problema **3**

3. Análisis Bibliográfico **4**

4. Desarrollo **6**

4.1. Redes Neuronales Artificiales (RNA) 7

4.2. Máquinas de Soporte Vectorial (SVM) 8

4.3. Development of Mathematical Expressions (DoME) 8

4.4. Árboles de Decisión 9

4.5. Algoritmo de k-vecinos (kNN) 9

5. Conclusiones **12**

6. Trabajo Futuro **13**

1. Introducción

La detección de minas submarinas mediante sonar es un campo realmente interesante y crítico para la seguridad marítima, ya que su presencia puede comprometer rutas comerciales, operaciones de investigación o incluso misiones de rescate. Los protocolos de hoy en día exigen sistemas que permitan operar en tiempo real y con una alta fiabilidad, y asi minimizar el riesgo de falsos negativos, que podrían causar grandes estragos.

Su primera aplicación se remonta a la primera guerra mundial, donde se utilizaba para localizar sumergibles, y desde entonces el sonar ha experimentado un desarrollo constante. Gorman y Sejnowski demostraron el potencial de las redes neuronales para clasificar ecos acústicos y distinguir cilindros metálicos de rocas naturales [1]. Su trabajo dio inicio a la integración de técnicas de aprendizaje autómatico en el procesamiento de señales de este tipo.

Uno de los retos más significativos es que los ecos provenientes de minas y rocas muestran marcas sonoras casi idénticas, lo que dificulta la identificación automática. A pesar de que los operadores poseen una alta calificación, pueden cometer fallos debido a la fatiga o a restricciones humanas. En esa situación, los modelos de aprendizaje automático se presentan para fortalecer la confiabilidad del sistema. Desde el revolucionario trabajo de Gorman y Sejnowski, que en 1988 integraron redes neuronales en el conjunto de datos Sonar [1], hasta las técnicas actuales que transforman series temporales en imágenes, cada progreso ha favorecido progresos notables en precisión y velocidad de procesamiento.

Este trabajo usa el dataset Sonar para comparar modelos supervisados (redes neuronales, árboles de decisión, etc.) en la clasificación automática de ecos sonar. Midiendo precisión, recall y F1-score, buscamos optimizar la predicción e identificar patrones acústicos que distingan amenazas de objetos inofensivos, agilizando decisiones en entornos de alta seguridad.

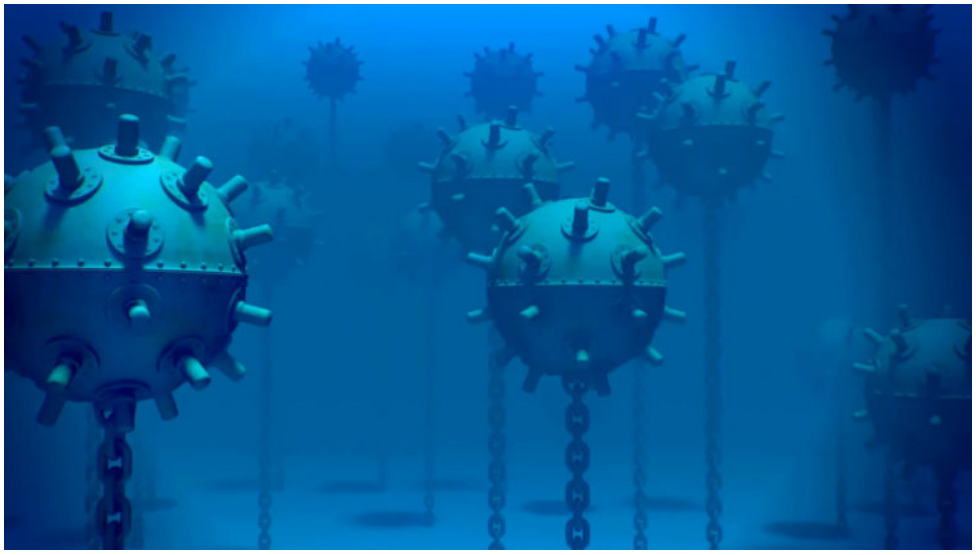


Figura 1: Minas Marinas. Fuente

2. Descripción del problema

Este trabajo se enfoca en la categorización de objetos submarinos basándose en señales sonoras adquiridas a través de un sistema de sonido activo. Cada muestra simboliza una emisión de sonido y el eco captado en 60 distintas bandas de frecuencia, cuyos valores se encuentran limitados entre 0 y 1. La meta es diferenciar de manera automática entre minas y rocas, empleando estas mediciones como elemento de entrada para modelos de aprendizaje automático.

El conjunto de datos utilizado, obtenido del Repositorio de Aprendizado Automático de UCI, incluye un total de 208 observaciones clasificadas en dos categorías:

- **M (Mina)**: 111 ejemplos (53.4 %)
- **R (Roca)**: 97 ejemplos (46.6 %)

Esta distribución es lo bastante balanceada para facilitar el entrenamiento de clasificadores sin la necesidad de utilizar métodos de reequilibrado de clases. La Figura 2 muestra gráficamente esta proporción.

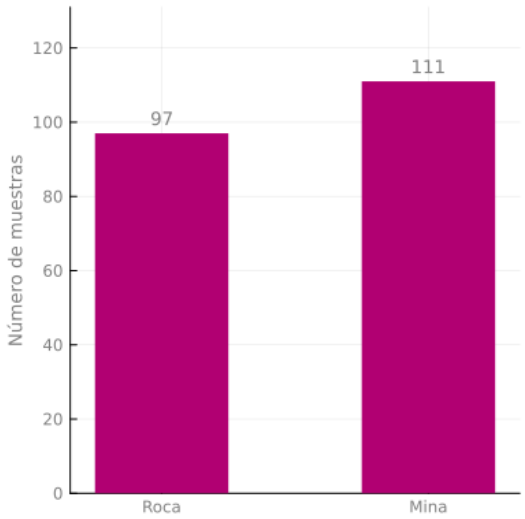


Figura 2: Distribución de clases en el conjunto de datos Sonar

Respecto a las propiedades de los datos, no existen valores nulos y todas las características ya están en un intervalo común entre 0 y 1. A pesar de que en otras situaciones podría ser beneficioso implementar una normalización extra (como Min-Max o centrado en media cero), en este escenario no se consideró imprescindible, dado que los datos presentaban una escala consistente y no se detectaron variaciones que justificaran una transformación adicional.

Al examinar las medias y desviaciones estándar de cada una de las 60 frecuencias por clase, se notan variaciones significativas entre las señales que emiten minas y rocas, particularmente en los intervalos medios del espectro. Este tipo de datos es fundamental para que los clasificadores sean capaces de identificar patrones de discriminación. La Figura 3 muestra estas diferencias.

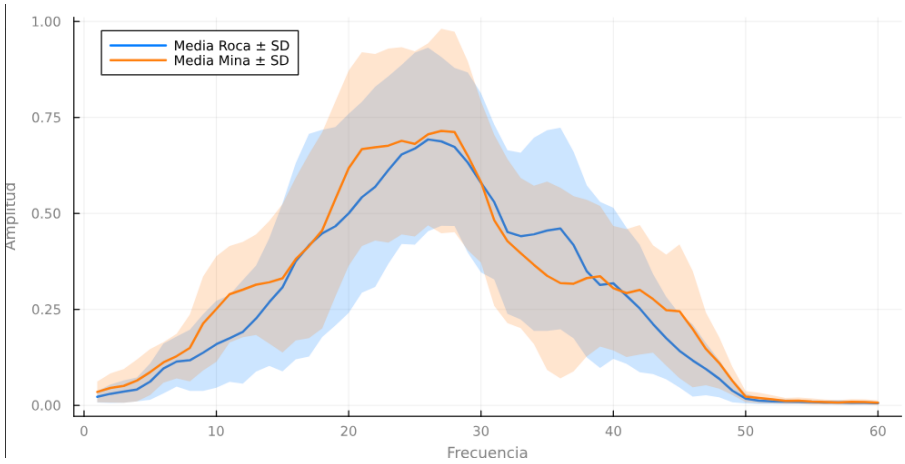


Figura 3: Media y desviación estándar por frecuencia y clase

En este escenario, incurrir en errores de clasificación puede acarrear repercusiones serias. Por ejemplo:

- **Falsos negativos (FN)**: No identificar una mina representa un inminente peligro para la seguridad.
- **Falsos positivos (FP)**: Clasificar una roca como mina implica una alarma engañosa y un desembolso superfluo de recursos.

Por lo tanto, además de la exactitud global, es necesario emplear métricas que representen de manera apropiada estos riesgos. La sensibilidad (recall) resulta esencial para reducir los falsos negativos, en tanto que el F1-score contribuye a mantener un balance entre sensibilidad y precisión en circunstancias con costos de error asimétricos.

3. Análisis Bibliográfico

La comprensión del conjunto de datos Sonar representa el punto de partida ideal para su aplicación en el ámbito del aprendizaje automático. A través de su análisis, podemos reconocer la abundante información que proporcionan las señales registradas, así como el equilibrio adecuado entre las clases objetivo. Esto lo convierte en un recurso adecuado e interesante para experimentos de clasificación binaria. Estas características no solo facilitan una interpretación más clara de los resultados obtenidos, sino que también posibilita establecer conexiones significativas entre los datos originales y los avances alcanzados en investigaciones recientes.

Con esta base, resulta pertinente examinar el contexto histórico y científico en el que surgió esta base de datos, así como las distintas estrategias que se han desarrollado para optimizar su aprovechamiento en tareas de clasificación a lo largo de los años.

Este análisis, llevado a cabo en 1988 por R. P. Gorman y T. J. Sejnowski, marcó un punto de inflexión en el uso de redes neuronales para el procesamiento de señales sonoras, y se transformó en uno de los primeros exitos en el ámbito de la clasificación de objetos submarinos. Es verdad que el área ha progresado significativamente desde esta investigación, pero este trabajo continúa siendo pertinente dado que estableció los fundamentos conceptuales y metodológicos para estudios futuros. Este método brindó un fundamento sólido para desarrollar modelos de aprendizaje automático que pudieran reconocer y categorizar estos patrones acústicos con una alta exactitud. [1]

Dos décadas despúes, en el 2008, Burcu Erkmen y Tülay Yildirim trataron el asunto de la categorización automática de minas submarinas en aguas poco profundas a través de redes neuronales de regresión general (GRNN) y el análisis de componentes principales (PCA) combinados. Frente a las restricciones del análisis manual realizado por especialistas, que es monótono y susceptible a fallos, su propuesta logró incrementar notablemente la exactitud al disminuir la dimensión del problema sin renunciar a datos significativos. El estudio se llevó a cabo mediante curvas ROC, lo que facilitó una evaluación sólida de la sensibilidad y especificidad del modelo. Los hallazgos evidenciaron que la mezcla de PCA y GRNN no solo aumentó la tasa de clasificación adecuada, sino que también disminuyó el gasto computacional. Esto

constituye un progreso significativo en comparación con los métodos anteriores, centrados únicamente en redes neuronales básicas. [**?**]

En 2012, Hao Fu y Guoping Qiu presentaron un avance metodológico significativo mediante la sincronización de histogramas entre kernels, utilizada para optimizar la mezcla de características en problemas de clasificación, incluyendo señales sonoras. A diferencia de técnicas convencionales que solo ajustan media y varianza, su metodología normaliza la distribución total de los kernels a una forma canónica habitual, antes de implementar técnicas de aprendizaje como el Multiple Kernel Learning (MKL). Al llevar a cabo su propuesta en el conjunto, consiguieron avances, aunque modestos, en la exactitud (pasando del 88.0 % al 88.2 %) y una disminución en la norma del hiperplano, lo que señala modelos más coherentes. Este trabajo enfatiza que incluso los progresos metodológicos generales, no específicos para el sonar, pueden influir de manera positiva en este de estudio. [2]

Dos años más tarde, en el 2016, Baida'a Abdul-Qader llevó a cabo una profunda comparación entre tres métodos de aprendizaje supervisado: las redes neuronales artificiales (RNA), los sistemas de inferencia neuro-difuso adaptativo (ANFIS) y los k-vecinos más cercanos (kNN), todos ellos aplicados al conjunto Sonar. Además de analizar los modelos utilizando las 60 características originales del dataset, implementó un proceso de selección secuencial de características (SFS), consiguiendo disminuirlos a los 50 más adecuados. Esta elección no solo incrementó la habilidad predictiva de los clasificadores, sino que redujo significativamente el tiempo de entrenamiento, particularmente en modelos como kNN, que a menudo tienen una alta sensibilidad a la dimensionalidad. Este trabajo destaca la relevancia de los métodos de preprocesamiento y elección, tanto de variables como de componentes para mejorar el desempeño de los sistemas de clasificación. [**?**]

En el 2019, Khishe y Mosavi presentaron el algoritmo bioinspirado Whale Trainer, para entrenar redes neuronales utilizadas en la clasificación de datos sonar. Este algoritmo, inspirado en la conducta social de las ballenas, contribuyó a superar los problemas habituales de mínimos locales durante el entrenamiento, logrando tasas de clasificación superiores y una mayor habilidad para generalizar ante el ruido. Además, aplicaron perceptrones multicapa entrenados con el algoritmo Salp Swarm, inspirado en el movimiento colectivo de los salpas marinas, logrando una reducción significativa en los errores de clasificación y una aceleración de la convergencia. [3] [4]

Ese mismo año, Wang et al. propusieron una red neuronal convolucional (CNN) que utilizaba pesos adaptativos para clasificar imágenes sonar. Esta arquitectura permitió una mejor representación espacial de los datos, que superaba a las CNN tradicionales tanto en precisión como en robustez. [5]

En 2021, Aybüke Civrizoğlu Buz, Mustafa Umut Demirezen y Uraz Yavanoğlu propusieron un enfoque disruptivo: transformar las señales sonar en imágenes usando Gramian Angular Field (GAF), Markov Transition Field (MTF) y Recurrence Plot (RP). Estas técnicas permiten convertir series temporales en representaciones visuales que contienen relaciones angulares, probabilidades de transición y patrones de repetición, respectivamente. Al combinar estas imágenes como canales rojos, verdes y azules en una única imagen RGB, fueron capaces de entrenar una CNN que alcanzó un 97.60 % de precisión, superando ampliamente a modelos como SVM o k-NN. Este estudio demuestra el enorme potencial de aplicar visión por computador al análisis de señales, abriendo nuevas posibilidades. [**?**] En paralelo, Manonmani et al. exploraron ese año técnicas clásicas de visión por computador, como Histogram of Oriented Gradients (HOG) y el detector de bordes de Canny, mostrando que, aunque fueran más simples, seguían siendo útiles como herramientas de preprocesamiento para reducir falsos positivos y mejorar la eficiencia en etapas posteriores. [6]

Al año siguiente, Vilas-Bôas Silveira et al. examinaron el uso de redes multicapa (MLP) aplicadas al reconocimiento de objetos submarinos, realizando experimentos tanto con datos sintéticos como reales. A pesar de la creciente tendencia hacia modelos más complejos como CNNs y redes bioinspiradas, los autores demostraron que los MLP, bien calibrados, pueden competir en precisión en contextos donde la eficiencia computacional es crucial. [7]

Los últimos avances sonados, en 2023, fueron cuando Mousavipour y Mosavi desarrollaron un modelo híbrido combinando los algoritmos Dragonfly y Chimp Optimization para entrenar redes neuronales aplicadas a datos sonar. Este enfoque permitió mejorar notablemente tanto la precisión de clasificación como la estabilidad durante el entrenamiento, también realizado con técnicas bioinspiradas. [8] Ese mismo año, Sitha et al. propusieron un enfoque de aprendizaje automático que integra algoritmos supervisados con preprocesamiento especializado, logrando reducir la tasa de falsos positivos y mejorar la precisión global. Este trabajo recalca la importancia del preprocesamiento, mostrando que incluso los mejores algoritmos pueden beneficiarse de una etapa previa bien diseñada para potenciar su desempeño, como ya pudimos apreciar en otros estudios ya mencionados anteriormente. [9]

4. Desarrollo

Una vez realizado el preprocesado de los datos, se pasó a entrenar y evaluar los distintos modelos seleccionados. En esta etapa se utilizaron cinco algoritmos de clasificación distintos, todos aplicados sobre el conjunto de datos Sonar ya preparado. El objetivo era que cada modelo pudiera aprender a relacionar correctamente las 60 frecuencias (atributos) con su clase correspondiente: mina o roca.

Los algoritmos utilizados fueron los siguientes:

- Redes Neuronales Artificiales (RNA)
- Máquinas de Soporte Vectorial (SVM)
- Estimación de Modelos de Decisión (DoME)
- Árboles de decisión
- Algoritmo de k-vecinos (k-NN)

El dataset está compuesto por 208 registros, de los cuales 111 pertenecen a la clase *mina* (53,4 %) y los 97 restantes a la clase *roca* (46,6 %). Al estar las clases relativamente equilibradas, los modelos pueden entrenarse sin necesidad de aplicar técnicas de balanceo.

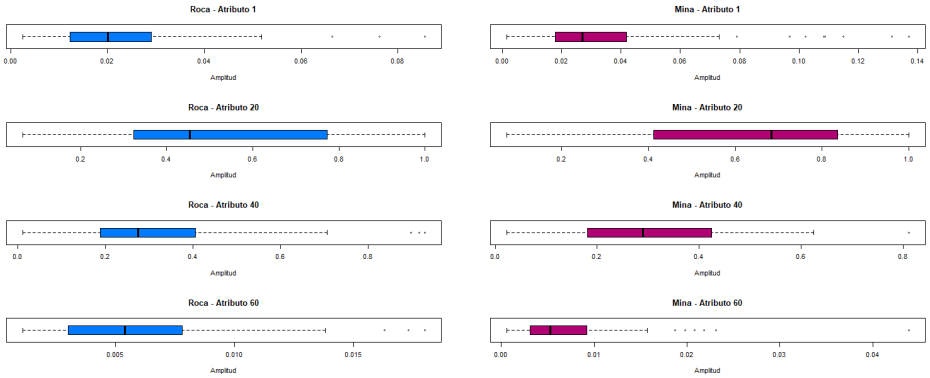


Figura 4: Diagrama de cajas de la distribución de normalidad del conjunto de datos

Cada atributo representa la intensidad registrada en una frecuencia concreta. Al observar los diagramas de caja (boxplots), se ve que en las frecuencias iniciales los valores están más concentrados y las diferencias entre clases son mínimas. Sin embargo, en las frecuencias más altas las diferencias se acentúan y los valores presentan más dispersión, aunque de forma algo irregular.

Para evitar el sobreajuste y tener una estimación fiable del rendimiento, se utilizó validación cruzada con $k = 8$. Es decir, los datos se dividieron en 8 partes, y el entrenamiento se repitió 8 veces rotando qué parte se usaba como test en cada ocasión. Esto asegura que todos los datos se usen para entrenar y para evaluar en algún momento.

La evaluación se hizo utilizando la matriz de confusión, que permite ver con detalle cuántos casos fueron bien o mal clasificados. Esta matriz incluye:

- Verdaderos Positivos (VP): minas clasificadas correctamente.
- Falsos Negativos (FN): minas clasificadas como rocas.
- Verdaderos Negativos (VN): rocas clasificadas correctamente.
- Falsos Positivos (FP): rocas clasificadas como minas.

A partir de la matriz se calculan métricas fundamentales para comparar los modelos:

- Precisión: porcentaje de aciertos totales.
- Error: porcentaje de fallos sobre el total.
- Sensibilidad (recall): capacidad para detectar minas correctamente.
- Especificidad: capacidad para identificar correctamente las rocas.
- VPP (valor predictivo positivo): precisión de las predicciones positivas.
- VPN (valor predictivo negativo): precisión de las predicciones negativas.
- F1-score: media armónica entre precisión y sensibilidad.

Estas métricas no solo permiten evaluar qué tan bien funciona un modelo, sino también si hay algún tipo de sesgo hacia una clase. Dado que no detectar una mina puede ser un error grave, se le da especial importancia a la sensibilidad, aunque siempre tratando de mantener un buen equilibrio con el resto de medidas.

4.1. Redes Neuronales Artificiales (RNA)

Las redes neuronales artificiales (RNA) se asemejan al funcionamiento del sistema nervioso humano, ya que están formadas por niveles de nodos vinculados que manejan la información mediante funciones de activación. En situaciones en las que se requiere de clasificación, como esta, permiten el establecimiento de relaciones no lineales.

En este trabajo, se han examinado varias estructuras alterando el número de capas y las neuronas escondidas. Las redes de una sola capa con más neuronas han probado tener un rendimiento superior en términos de precisión y puntaje F1 en comparación con las de dos capas, lo que sugiere que una arquitectura más profunda no siempre implica un rendimiento superior cuando la cantidad de datos es limitada.

Cuadro 1: Resultados comparativos de las arquitecturas de una y dos capas

Métrica	**[16]**	**[32]**	**[16, 2]**
Exactitud (Acc)	0.779 ± 0.048	0.789 ± 0.060	0.752 ± 0.040
Error (Err)	0.221 ± 0.048	0.211 ± 0.060	0.248 ± 0.040
Sensibilidad (Rec)	0.704 ± 0.081	0.714 ± 0.077	0.628 ± 0.088
Especificidad (Spec)	0.842 ± 0.138	0.853 ± 0.145	0.859 ± 0.136
VPP (Prec)	0.821 ± 0.104	0.837 ± 0.116	0.835 ± 0.109
VPN (NPV)	0.770 ± 0.028	0.776 ± 0.034	0.737 ± 0.026
F1	0.748 ± 0.038	0.761 ± 0.049	0.690 ± 0.034

4.2. Máquinas de Soporte Vectorial (SVM)

Las SVM son modelos supervisados que intentan separar las clases a través de un hiperplano con el margen más amplio posible. El modelo facilita la implementación de transformaciones no lineales a los datos mediante funciones *kernel*, lo que mejora la habilidad del clasificador en grupos que poseen estructuras complejas.

En este caso, se han evaluado diferentes configuraciones combinando parámetros como el coeficiente de penalización C y el valor de γ, que controla la influencia de cada muestra. Las SVM con *kernel* no lineal mostraron mejor rendimiento que las lineales, sobre todo en sensibilidad y en el balance global entre métricas.

1. kernel: *linear* C: 0.1
2. kernel: *rbf* C: 1.0 γ: 0.05
3. kernel: *poly* C: 5.0 γ: 0.1 degree: 3 coef0: 1.0

Cuadro 2: Resultados SVM (Configuraciones 1-3)

Métrica	**1**	**2**	**3**
Precision	0.720 ± 0.062	0.706 ± 0.083	0.831 ± 0.047
Error rate	0.280 ± 0.062	0.294 ± 0.083	0.169 ± 0.047
Sensitivity	0.556 ± 0.110	0.536 ± 0.117	0.784 ± 0.076
Specificity	0.863 ± 0.095	0.854 ± 0.116	0.872 ± 0.089
VPP	0.796 ± 0.116	0.782 ± 0.141	0.854 ± 0.083
VPN	0.692 ± 0.054	0.679 ± 0.070	0.825 ± 0.049
F1	0.646 ± 0.091	0.627 ± 0.104	0.813 ± 0.048

4.3. Development of Mathematical Expressions (DoME)

El algoritmo DoME (Development of Mathematical Expressions) es una técnica de regresión simbólica que construye ecuaciones matemáticas interpretables. Representa las expresiones como árboles y mejora su estructura mediante búsquedas locales, sustituyendo los nodos por subárboles que reducen el error. Su diseño nos permite controlar la complejidad del algoritmo ajustando parámetros como el número máximo de nodos.

En esta práctica, DoME se ha aplicado al conjunto de mediciones acústicas submarinas y se han probado distintas configuraciones: 10, 20 y 30 nodos, para analizar cómo influye la complejidad en su rendimiento.

Cuadro 3: Resultados DoME (Nodos 10-30)

Métrica	**10 nodos**	**20 nodos**	**30 nodos**
Precisión	0.755 ± 0.088	0.725 ± 0.108	0.807 ± 0.117
Error rate	0.245 ± 0.088	0.275 ± 0.108	0.193 ± 0.117
Sensitivity	0.732 ± 0.105	0.743 ± 0.066	0.764 ± 0.119
Specificity	0.774 ± 0.106	0.710 ± 0.157	0.844 ± 0.172
VPP	0.745 ± 0.105	0.707 ± 0.139	0.835 ± 0.163
VPN	0.770 ± 0.090	0.752 ± 0.083	0.803 ± 0.096
F1	0.736 ± 0.091	0.721 ± 0.096	0.791 ± 0.117

4.4. Árboles de Decisión

Los árboles de decisión segmentan los datos de manera gradual basándose en los atributos: Estos crean un modelo que se puede representar como una estructura jerárquica de decisiones. Su mayor beneficio es la interpretación, puesto que cada elección puede seguirse de manera clara hasta su respectiva clasificación.

En este estudio, se ha alterado la máxima profundidad del árbol para analizar cómo la complejidad del modelo influye en su desempeño.

Cuadro 4: Métricas de desempeño por profundidad máxima (4, 8, 12)

Métrica	**Max depth 4**	**Max depth 8**	**Max depth 12**
Precisión	0.731 ± 0.057	0.726 ± 0.039	0.726 ± 0.039
Error rate	0.269 ± 0.057	0.274 ± 0.039	0.274 ± 0.039
Sensitivity	0.668 ± 0.143	0.711 ± 0.079	0.711 ± 0.079
Specificity	0.783 ± 0.117	0.739 ± 0.092	0.739 ± 0.092
VPP	0.744 ± 0.094	0.711 ± 0.057	0.711 ± 0.057
VPN	0.742 ± 0.081	0.748 ± 0.042	0.748 ± 0.042
F1	0.694 ± 0.077	0.707 ± 0.042	0.707 ± 0.042

4.5. Algoritmo de k-vecinos (kNN)

El algoritmo de los kkk vecinos más cercanos (k-NN) se basa en calcular la distancia entre una nueva muestra y todas las del conjunto de entrenamiento, y asignarle la clase que más se repite entre sus kkk vecinos más próximos. La elección de kkk es crucial, ya que determina cuántos puntos se tienen en cuenta para tomar la decisión.

Su rendimiento puede verse afectado si no se elige un valor adecuado de kkk, y también puede volverse más lento si se trabaja con bases de datos muy grandes, ya que tiene que calcular distancias con todos los puntos.

Cuadro 5: Resultados kNN (k = 3, 5, 7)

Métrica	**k = 3**	**k = 5**	**k = 7**
Precisión	0.803 ± 0.046	0.813 ± 0.058	0.750 ± 0.091
Error rate	0.197 ± 0.046	0.187 ± 0.058	0.250 ± 0.091
Sensitivity	0.710 ± 0.067	0.743 ± 0.066	0.651 ± 0.100
Specificity	0.884 ± 0.108	0.874 ± 0.073	0.837 ± 0.093
VPP	0.860 ± 0.118	0.842 ± 0.087	0.782 ± 0.121
VPN	0.779 ± 0.033	0.796 ± 0.050	0.732 ± 0.078
F1	0.772 ± 0.047	0.788 ± 0.066	0.709 ± 0.104

Discusión

Al evaluar el rendimiento de los distintos modelos sobre el conjunto de datos *Sonar*, se observan comportamientos variados según el tipo de algoritmo y la configuración aplicada.

Las redes neuronales artificiales (RNA) con arquitecturas de una sola capa (por ejemplo, 16 o 32 neuronas) han demostrado un rendimiento sólido y equilibrado. La configuración de 32 neuronas alcanzó una precisión del 83.6 % y un F1-score del 76.1 % (ver Tabla 1), superando al resto de arquitecturas neuronales más profundas. En cambio, la configuración con dos capas (16-2) mostró una caída notable en la sensibilidad y en el F1-score, lo que sugiere que aumentar la profundidad en este caso puede provocar sobreajuste, sin que ello implique una mejora real sobre el conjunto de datos actual.

En el caso de las máquinas de vectores soporte (SVM), se aprecia un fuerte contraste entre configuraciones. La versión con *kernel* polinómico (grado 3, $C = 5{,}0$) sobresale con métricas muy equilibradas: precisión del 85.3 %, sensibilidad del 78.4 % y F1-score del 81.3 % (ver Tabla 2). Por el contrario, las variantes lineal y RBF con valores bajos de C muestran rendimientos considerablemente más bajos, especialmente en sensibilidad (por debajo del 55 %), lo que indica una menor capacidad para detectar correctamente las clases objetivo. Esto refuerza la idea de que, para datos con patrones complejos como los presentes, es preferible emplear *kernels* no lineales y configuraciones con mayor regularización.

El modelo DoME, con un máximo de 30 nodos, ofreció un desempeño muy competitivo: F1-score de 79.1 % y precisión de 83.5 % (ver Tabla 3), destacando por su estabilidad a lo largo de las distintas ejecuciones. Este comportamiento lo convierte en una alternativa atractiva cuando se busca un equilibrio entre rendimiento y robustez, sin depender tanto de una configuración específica.

Los *árboles de decisión* mostraron mejoras progresivas con el aumento de la profundidad. Con profundidades bajas (4), el rendimiento fue limitado (precisión aproximada del 74 %, F1 del 69 %). Al incrementarla a 8 o 12, se logró estabilizar el F1 en torno al 70.7 % (ver Tabla 4), aunque sin mejoras sustanciales entre ambas profundidades, lo que sugiere un punto de saturación más allá del cual no se obtienen beneficios significativos, e incluso podría comenzarse a sobreajustar.

En cuanto a k-NN, los valores de k más bajos ($k = 3$ y $k = 5$) ofrecieron los mejores resultados. La configuración con $k = 5$ alcanzó un F1-score de 78.8 % y una precisión superior al 84 % (ver Tabla 5), destacando por su capacidad para capturar patrones locales relevantes. En cambio, con $k = 7$, las métricas cayeron de forma notable, lo que indica que al aumentar el número de vecinos se pierde sensibilidad al detalle, generando clasificaciones menos precisas.

En conjunto, los resultados permiten afirmar que tanto SVM (con *kernel* polinómico) como k-NN (con k bajo) y DoME (con mayor número de nodos) son las opciones más destacadas en este problema, presentando un buen equilibrio entre precisión, sensibilidad y estabilidad.

Para reforzar el análisis de rendimiento, se han incluido dos matrices de confusión promedio: una correspondiente a la mejor arquitectura de red neuronal ([32]) y otra a la mejor configuración de SVM, usando kernel polinómico con $C = 5{,}0$ y $\gamma = 0{,}1$. Estas matrices permiten ver con más claridad dónde se producen los aciertos y errores en la clasificación.

	Pred. Mina	**Pred. Roca**
Real Mina	95	16
Real Roca	28	69

(a) RNA [32]

	Pred. Mina	**Pred. Roca**
Real Mina	97	14
Real Roca	21	76

(b) SVM (kernel polinómico)

Figura 5: Matrices de confusión promedio para las configuraciones más eficaces de RNA y SVM

Como se observa, los modelos ofrecen resultados aceptables, pero con matices. La red neuronal tiene algo más de dificultad para identificar correctamente todas las minas, ya que presenta un mayor número de falsos negativos. En cambio, la SVM mejora en este aspecto y logra un equilibrio más ajustado. Esta diferencia es de gran importancia en este caso donde fallar al detectar una mina puede tener consecuencias graves.

Para facilitar la comprensión entre los diferentes modelos evaluados, se ha elaborado un gráfico de líneas que muestra las métricas medias de rendimiento para cada algoritmo. Esto permite evaluar de manera general que modelo funciona mejor de manera general, otorgando poca importancia a los parámetros seleccionados.

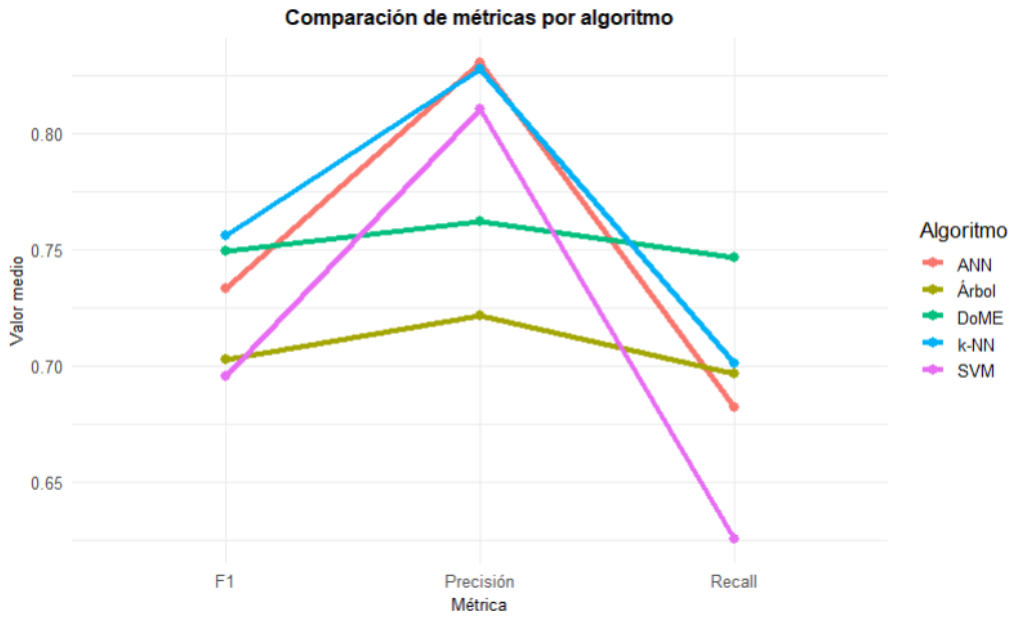


Figura 6: Comparación de métricas medias (Precisión, Recall y F1-score) por algoritmo.

Como se puede apreciar en la Figura 6, los modelos que mejor conservan un balance entre las tres métricas son la SVM con kernel polinómico y el algoritmo DoME. En ambas situaciones, las curvas se conservan sobre el 80 % en la mayoría de los ejes. En cambio, la RNA, a pesar de su buen desempeño en precisión, presenta un descenso más significativo en la sensibilidad.

A continuación se muestra un cuadro resumen con las principales métricas obtenidas por los mejores casos de los modelos evaluados. Se incluyen valores medios y desviaciones típicas para cada métrica. El objetivo es identificar cuál de ellos ofrece un mejor rendimiento en esos casos en particular.

Cuadro 6: Comparativa resumen final de modelos evaluados

Métrica	**RNA [32]**	**SVM (*poly*, 5, 0.1)**	**Árbol (Prof. 8)**	**k-NN ($k = 5$)**	**DoME ($n = 30$)**
Precisión	0.789 ± 0.060	0.831 ± 0.047	0.726 ± 0.039	0.813 ± 0.058	0.807 ± 0.117
Error rate	0.211 ± 0.060	0.169 ± 0.047	0.274 ± 0.039	0.187 ± 0.058	0.193 ± 0.117
Sensitivity	0.714 ± 0.077	0.784 ± 0.076	0.711 ± 0.079	0.743 ± 0.066	0.764 ± 0.119
Specificity	0.853 ± 0.145	0.872 ± 0.089	0.739 ± 0.092	0.874 ± 0.073	0.844 ± 0.172
VPP	0.837 ± 0.116	0.854 ± 0.083	0.711 ± 0.057	0.842 ± 0.087	0.835 ± 0.163
VPN	0.776 ± 0.034	0.825 ± 0.049	0.748 ± 0.042	0.796 ± 0.050	0.803 ± 0.096
F1	0.761 ± 0.049	0.813 ± 0.048	0.707 ± 0.042	0.788 ± 0.066	0.791 ± 0.117

5. Conclusiones

En conjunto, los resultados obtenidos han sido bastante buenos. Las configuraciones mejor ajustadas han conseguido precisiones por encima del 80 % y F1-scores muy destacables, lo que demuestra que el problema es abordable usando técnicas supervisadas variadas.

Las redes neuronales artificiales, especialmente las que usan una sola capa con 32 neuronas, han sido las que mejor se han comportado. Han alcanzado un F1 medio del 76 % y una precisión en torno al 84 %. Por el contrario, las arquitecturas con dos capas han tenido un rendimiento notablemente inferior, lo que sugiere que en este caso concreto una red más compleja no mejora los resultados. De hecho, cuando los datos son limitados, parece que compensa más usar una red más simple pero con una capa suficientemente amplia.

En cuanto a las máquinas de soporte vectorial, el rendimiento ha dependido mucho del tipo de kernel y de cómo se configuraron los parámetros. El mejor resultado se obtuvo usando un kernel polinómico con $C = 5{,}0$ y $\gamma = 0{,}1$, alcanzando un F1 del 81 % y una precisión del 85 %. Sin embargo, las configuraciones con kernel lineal o RBF más conservadoras funcionaron mucho peor, especialmente en sensibilidad, que bajó incluso del 55 %. Esto muestra que las SVM pueden ser muy potentes, pero que dependen mucho de cómo se ajusten sus parámetros.

El algoritmo DoME ha sido especialmente consistente. Con 30 nodos logró una precisión cercana al 80 % y un F1 del 79 %. Aunque no consiguió superar al mejor modelo de SVM, su rendimiento ha sido bastante equilibrado en todas las pruebas, lo que lo convierte en una opción muy interesante en cuanto a estabilidad.

En el caso de los árboles de decisión, se vio una mejora al aumentar la profundidad de 4 a 8, pero pasar a 12 no aportó mejoras. En general, se han mantenido con F1 en torno al 70 %, lo que está bien, aunque por debajo de otros métodos más complejos. Su ventaja radica en que ofrecen una gran interpretabilidad, lo que puede ser útil en determinados contextos.

Finalmente, el algoritmo k-NN ha ofrecido resultados bastante buenos con valores bajos de k. Usando $k = 5$ se logró un F1 del 78 % y precisión del 81 %, colocándose como uno de los modelos con mejor rendimiento. Eso sí, al subir el valor de k a 7, las métricas bajaron, lo que sugiere que con demasiados vecinos se pierde sensibilidad a los patrones locales, algo clave en este tipo de tareas.

Para concluir, este gráfico de barras resume las métricas más importantes (F1, precisión y sensibilidad) obtenidas por el mejor caso de cada algoritmo. Gracias a esta representación es más fácil comparar de un vistazo el comportamiento general de los modelos y ver cuáles mantienen un buen equilibrio entre métricas y cuáles destacan más en alguna concreta.

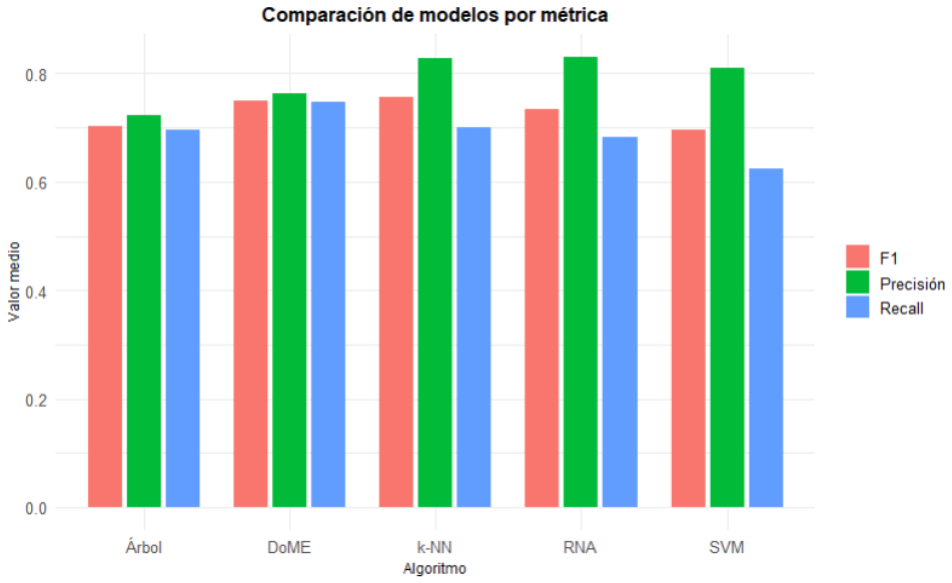


Figura 7: Comparación de modelos por métrica (F1, Precisión y Sensibilidad)

6. Trabajo Futuro

A partir de los hallazgos obtenidos en esta práctica, se abren varias posibilidades interesantes para seguir explorando y evolucionando el sistema de clasificación propuesto.

Una de las vías más evidentes sería pasar de un enfoque binario como este caso, centrado exclusivamente en diferenciar entre minas y rocas, a un modelo de clasificación multiclase. Esto permitiría incluir nuevas categorías relevantes, como estructuras artificiales (tuberías, cables), elementos naturales (bancos de arena, algas) o incluso fauna marina. Esto lo convertiría en un modelo más versátil y con mayor aplicabilidad en contextos reales.

De querer seguir con esta línea de trabajo, sería imprescindible recopilar nuevos conjuntos de datos más diversos, o bien generar simulaciones acústicas realistas que incluyan ruido o condiciones más exigentes. Este salto también exigiría técnicas adicionales de tratamiento de datos y modelos con mayor robustez.

Otra posible aplicación interesante es el uso de estas técnicas en contextos como la pesca. Por ejemplo, podrían adaptarse para detectar bancos de peces a partir de señales de sonda. En este caso concreto, ya existen bases de datos públicas, como el NOAA Fisheries Acoustics Dataset [10], que facilitarían el entrenamiento y validación de los modelos. Eso sí, el tipo de señal y el tipo de objeto serían muy diferentes, lo que obligaría a adaptar los modelos a cada zona y sus características y patrones.

También resulta interesante pensar en la aplicación de este enfoque en campos como el análisis de actividad sísmica o volcánica. Ambos comparten una estructura de datos basada en señales temporales, donde los eventos relevantes aparecen como patrones dentro de largas secuencias de datos. Por eso, podrían beneficiarse del mismo tipo de modelos y técnicas de clasificación utilizados en esta práctica, aunque sería necesario adaptar la escala temporal, la resolución de muestreo y el rango del espectro de trabajo. Aplicar modelos de este tipo permitiría, por ejemplo, detectar de forma automática temblores, explosiones o movimientos de magma, mejorando los sistemas de alerta temprana o la monitorización en tiempo real.

Una línea de trabajo especialmente útil sería la integración del sistema en drones submarinos o vehículos autónomos, que utilizan el sonar para desplazarse por el fondo marino sin intervención directa. En este caso, el clasificador podría ayudar a evitar obstáculos como minas o rocas, mejorando la seguridad y eficiencia de las misiones. Además, si se combina con una interfaz visual sencilla para los operadores humanos, sería posible supervisar las detecciones en tiempo real, viendo qué objeto ha sido identificado, con qué nivel de confianza, y en qué posición. Este enfoque permitiría aplicar el sistema no solo en pruebas controladas, sino en misiones reales de exploración, rescate o vigilancia.

Otra mejora interesante sería que el sistema pudiera actualizarse en tiempo real. La idea es que, cada vez que se clasifique una señal y se conozca si el resultado ha sido correcto o no, esa información se guarde al instante y se utilice directamente para ajustar el modelo. Esto permitiría que el sistema se fuese adaptando continuamente, sin necesidad de esperar a un nuevo entrenamiento completo. De este modo, el clasificador podría responder mejor a cambios en el entorno o a patrones nuevos, mejorando su rendimiento justo donde más se necesita.

En resumen, las posibilidades de ampliación son numerosas y abarcan desde mejoras del propio sistema hasta su transferencia a nuevos dominios de aplicación, generando nuevas oportunidades tanto técnicas como científicas.

Referencias

[1] R. P. Gorman and T. J. Sejnowski. Analysis of hidden units in a layered network trained to classify sonar targets. *Neural Networks*, 1(1):75–89, 1988.

[2] Hao Fu and Guoping Qiu. Histogram matching for kernel based feature combination. 2012.

[3] M. Khise and M. R. Mosavi. Improved whale trainer for sonar datasets classification using neural network. *Applied Acoustics*, 154:176–192, 2019.

[4] M. Khise and H. Mohammadi. Passive sonar target classification using multi-layer perceptron trained by salp swarm algorithm. *Ocean Engineering*, 181:98–108, 2019.

[5] X. Wang et al. Underwater sonar image classification using adaptive weights convolutional neural network. *Applied Acoustics*, 146:145–154, 2019.

[6] S. Manonmani et al. Underwater mine detection using histogram of oriented gradients and canny edge detector. In *International Carnahan Conference on Security Technology (ICCST)*. IEEE, 2021.

[7] I. Vilas-Bôas Silveira et al. A multi-layer perceptron model for underwater object recognition. *Journal of Bioengineering of Technology Applied to Health*, 5(4):266–271, 2022.

[8] F. Mousavipour and M. R. Mosavi. Sonar data classification using neural network trained by hybrid dragonfly and chimp optimization algorithms. *Wireless Personal Communications*, 129(1):191–208, 2023.

[9] R. M. Sitha et al. Machine learning based underwater mine detection. In *International Conference on Intelligent Computing and Control Systems (ICICCS)*. IEEE, 2023.

[10] NOAA Fisheries. Fisheries acoustics research data. Online, 2025. Available: Passive Acoustic Data — National Centers for Environmental Information (NCEI).